UNIVERSIDAD DEL VALLE DE GUATEMALA
Facultad de Ingeniería
Deep Learning 2026

¿Vale la pena leer el orden de las transacciones?

Informe al comité de riesgos del Banco del Altiplano

Proyecto 1: monitoreo transaccional

Angel Herrarte 22873
Jorge López 221038

Catedrático: Kevin Recinos
Guatemala, 4 de septiembre de 2026

1. Resumen

El área de riesgos sostiene que en los fraudes que se escapan el patrón está en el orden de las transacciones y no en los montos. Lo pusimos a prueba. Estos son los hallazgos:

- **El orden sí aporta.** Un modelo que lee la secuencia detecta el 89.6% de los ataques de prueba y cobro, contra 80.1% del enfoque actual basado en variables agregadas.
- **Pero solo en un caso.** En los otros dos mecanismos que probamos, los dos enfoques empatan. La ventaja se concentra por completo en un solo tipo de fraude.
- **La prueba de refutación lo confirma.** Al barajar el orden de las transacciones sin cambiar ninguna de ellas, el modelo secuencial cae de 0.882 a 0.018 de AUC-PR. El de agregados no se mueve.
- **En quetzales.** El ahorro estimado es 9.5% del costo mensual de fraude frente al enfoque actual.

Recomendamos complementar el motor antifraude actual, no reemplazarlo. La sección 8 explica bajo qué condiciones cambiaría esa recomendación.

2. Qué preguntamos y cómo lo montamos

La pregunta no es si se puede entrenar un modelo de secuencias. Es si el orden trae información que las variables agregadas no tienen, en qué casos, y cuánto vale.

Para responderla comparamos tres modelos que reciben la misma información con distinta forma, sobre la misma ventana de 20 transacciones de la tarjeta.

Modelo	Qué recibe	Qué representa
A	los agregados de la ventana, ya resumidos	el motor actual del banco
B	los 20 eventos en orden, sin resumir	leer la secuencia
C	las dos cosas a la vez	la apuesta del equipo

Ninguno ve nada que el otro no tenga. Si al modelo A le diéramos menos información, ganarle no probaría nada sobre el orden: probaría que al modelo B le dimos más datos.

Cada modelo puntúa una transacción en el momento de autorizarla. Elegimos esa unidad porque es lo que hace el motor actual, y porque los costos que nos dieron están expresados por transacción.

3. Los datos *evidencia 1*

3.1 Composición del conjunto

Concepto	Valor
Transacciones	484,753
Tarjetas	6,000
Período simulado	180 días
Tasa de fraude global	0.66%
Ventana por transacción	20 eventos previos de la misma tarjeta
Origen	generador sintético propio, reproducible por semilla

Los datos son sintéticos y esa es la principal limitación del trabajo. La declaramos de entrada.

La razón de haberlo hecho así es que necesitábamos saber qué mecanismo produjo cada fraude. Con datos reales eso no se puede: la etiqueta dice fraude y no dice de qué tipo. Sin ese dato, la tabla de la sección 5.2, que es la evidencia central de este informe, no existiría.

3.2 Los cuatro mecanismos de fraude

Mecanismo	Cómo se ve	¿Depende del orden?
F1, prueba y cobro	3 a 6 compras de Q5 a Q40 en minutos, y después una de Q2,000 a Q8,000	sí
F2, viaje imposible	dos transacciones en ciudades lejanas separadas por minutos	a medias

F3, toma de cuenta	ráfaga de comercio electrónico caro, de madrugada, en rubros nunca usados	no
F4, goteo lento	cargos de Q80 a Q200 del mismo comercio cada pocos días	fuera del entrenamiento

Los elegimos así a propósito, para que el resultado no saliera parejo. Si el modelo secuencial ganara en todos, habría motivo para desconfiar del generador.

3.3 El señuelo

Si F1 fuera nada más varias compras chicas seguidas de una grande, las variables agregadas lo resolverían solas y no habría nada que investigar. Por eso generamos también un señuelo legítimo: las mismas compras chicas, los mismos intervalos entre ellas, los mismos rubros y la misma compra grande al final. Lo único distinto es que en el fraude las compras chicas van de menor a mayor, y en el señuelo van revueltas.

Esa rampa es la firma del ataque. Quien roba la tarjeta va probando montos cada vez más altos para ver hasta dónde aguanta antes de cobrar.

Verificamos que el señuelo cumple su función entrenando el modelo de agregados para separar fraude de señuelo. Si pudiera hacerlo, el experimento entero no valdría.

Dónde se mide	ROC-AUC	Lectura
En la transacción del cobro	0.539	prácticamente azar
En todas las transacciones del episodio	0.617	algo de señal residual

Los agregados alcanzan a ver parte del reconocimiento, pero se quedan ciegos justo en el cobro, que es donde están los Q2,000 a Q8,000.

3.4 Partición temporal

Lo más viejo entrena, lo de en medio valida, lo último prueba. Entre bloques dejamos dos días de embargo que se descartan, para que ningún episodio de fraude quede partido en la frontera.

Bloque	Días	Transacciones	Fraudes	Tasa
Entrenamiento	0 a 119	323,007	1,987	0.62%
Embargo	120 a 121	descartado	—	—
Validación	122 a 149	75,536	518	0.69%
Embargo	150 a 151	descartado	—	—
Prueba	152 a 179	75,459	620	0.82%

Las mismas tarjetas aparecen en los tres bloques. Es correcto: partimos por tiempo y no por cliente, que es como funcionaría en producción.

La tasa de fraude es mayor en prueba porque ahí metimos el mecanismo F4, que ningún modelo vio durante el entrenamiento. Tiene una consecuencia que conviene tener presente al leer las tablas siguientes: como el AUC-PR depende de qué tan frecuente sea el fraude, las columnas de validación y de prueba no son comparables entre sí.

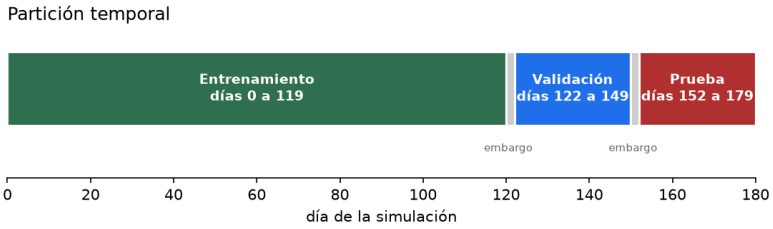


Figura 1. Partición temporal del conjunto de datos.

3.5 Controles contra fuga de información

Verificamos cinco controles y los dejamos como pruebas automáticas que fallan si alguien los rompe más adelante:

- Los escaladores se ajustan únicamente con el bloque de entrenamiento.
- Los tres bloques no se traslapan en el tiempo.

- Los agregados de cada transacción miran solo hacia atrás, nunca a sí mismos.
- El mecanismo F4 no aparece antes del bloque de prueba.
- Los umbrales se eligen sobre validación.

El conjunto de prueba se abrió una sola vez, al final, con todas las decisiones ya congeladas.

4. A contra B: el resultado de la comparación *evidencia 2*

Reportamos AUC-PR, el área bajo la curva de precisión contra exhaustividad. No usamos exactitud como métrica principal: con menos de 1% de fraude, un modelo que nunca alerte acierta más del 99% de las veces y no sirve para nada.

Modelo	AUC-PR validación	AUC-PR prueba	Umbral	Precisión	Exhaustividad	F1
A, agregados	0.810	0.549	0.799	0.438	0.653	0.525
B, secuencia	0.882	0.610	0.648	0.480	0.685	0.564
C, híbrido	0.857	0.600	0.307	0.441	0.666	0.531

El modelo secuencial le saca 0.072 de AUC-PR al de agregados en validación, con exactamente la misma información de entrada.

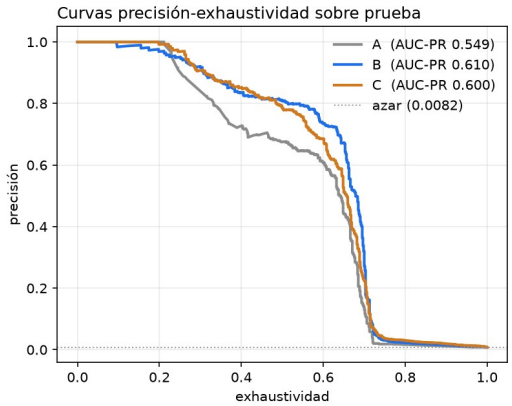


Figura 2. Curvas de precisión contra exhaustividad sobre el conjunto de prueba.

5. ¿De verdad está usando el orden? *evidencia 3*

Que las métricas suban no prueba que el modelo esté leyendo el orden. Podría estar aprovechando cualquier otra cosa. Hicimos dos pruebas diseñadas para tumbar nuestra propia conclusión.

5.1 Primera prueba: barajar el orden

Tomamos las mismas transacciones, con los mismos montos, comercios y horarios, y las revolvimos dentro de cada secuencia. Si el modelo estuviera usando otra cosa, su desempeño no debería moverse.

Modelo	Original	Historia barajada	Orden destruido	Caída
A, agregados	0.810	0.810	0.810	ninguna
B, secuencia	0.882	0.678	0.018	−0.864
C, híbrido	0.857	0.705	0.133	−0.724

El modelo secuencial pierde 0.204 solo con barajar la historia, y se derrumba a 0.018 cuando destruimos el orden por completo. El modelo de agregados no se mueve ni un decimal, que es exactamente lo que tenía que pasar: sus variables son promedios y conteos, y a un promedio no le importa en qué orden llegaron los números. Ese renglón es nuestro control de que la prueba está bien hecha. Si se hubiera movido, el error habría estado en nuestro código.

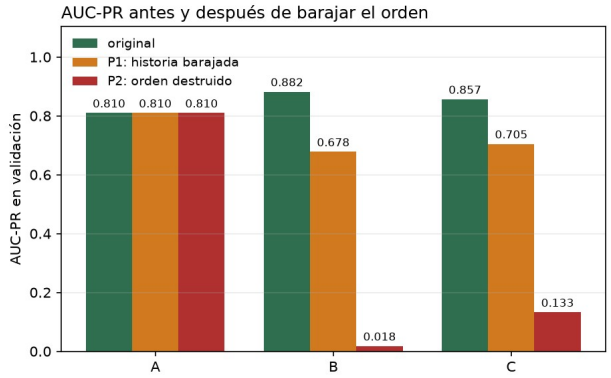


Figura 3. AUC-PR antes y después de barajar el orden, sobre validación.

5.2 Segunda prueba: un mecanismo que el modelo nunca vio

El goteo lento aparece únicamente en el conjunto de prueba. Nunca entró al entrenamiento. Queríamos saber qué pasa cuando llega un patrón de fraude nuevo.

Mecanismo	Casos	A	B	C	Lectura
F1, prueba y cobro	211	0.801	0.896	0.839	B gana
F2, viaje imposible	103	1.000	1.000	1.000	empate
F3, toma de cuenta	133	1.000	1.000	1.000	empate
F4, goteo lento	173	0.000	0.000	0.000	fallan los tres

Esta es la tabla más importante del informe, y lo es porque el resultado no sale parejo. En F3, que es una anomalía de monto y contexto sin nada que ver con el orden, el enfoque actual iguala al modelo secuencial, lo que confirma que la línea base no está amañada: donde los agregados alcanzan, alcanzan.

En F1, que construimos para depender del orden, el modelo secuencial saca casi diez puntos de exhaustividad. Y es el único mecanismo donde le gana.

En F4 fallan los tres. Lo dejamos así deliberadamente, y volvemos sobre ese punto en la sección 8.

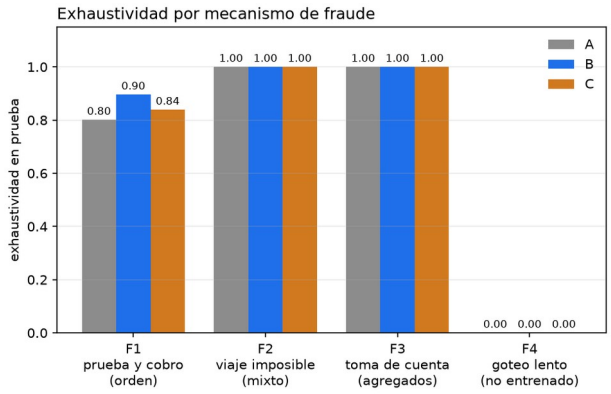


Figura 4. Exhaustividad por mecanismo de fraude sobre el conjunto de prueba.

6. La hipótesis del equipo *evidencia 4*

Antes de entrenar cualquier modelo dejamos escrita esta apuesta:

> *El modelo híbrido va a superar al mejor de A y B por al menos 0.02 de AUC-PR en validación, y esa mejora se va a sostener en el desglose por mecanismo.*

Fijamos el criterio de éxito de antemano, incluida la segunda condición. Sin ella, una mejora concentrada en un solo tipo de fraude contaría como éxito sin demostrar que las dos representaciones se complementan, que era lo que estábamos afirmando.

Concepto	Valor

Mejor de A y B en validación	0.882
Híbrido en validación	0.857
Margen obtenido	−0.026
Margen exigido	+0.020
Veredicto	hipótesis rechazada

No se cumplió. El híbrido quedó 0.026 por debajo del modelo secuencial, cuando pedíamos 0.02 por arriba.

Lo reportamos porque el resultado negativo también es información. Sugiere que darle los agregados a un modelo que ya recibe los eventos crudos no le agrega nada, porque puede reconstruir esos resúmenes por su cuenta.

Hay un detalle que mencionamos por transparencia. En el conjunto de prueba el híbrido queda casi empatado con el secuencial. No cambiamos el veredicto por eso: el criterio se fijó sobre validación antes de abrir prueba, y reescribirlo después de ver el resultado sería precisamente el error que la disciplina experimental busca evitar.

7. Dónde poner el umbral y cuánto cuesta *evidencia 5*

Con Q4,200 por fraude no detectado y Q180 por bloquear una compra legítima, la relación es de 23 a 1. Conviene bloquear de más, así que el umbral óptimo sale bajo.

Lo elegimos minimizando el costo esperado sobre validación, lo congelamos, y lo aplicamos una sola vez a prueba.

Modelo	Umbral	Fraudes que se escapan	Compras buenas bloqueadas	Costo mensual	Ahorro
A, agregados	0.799	215	519	Q 249,105,000	—
B, secuencia	0.648	195	461	Q 225,495,000	9.5%
C, híbrido	0.307	207	524	Q 240,930,000	3.3%

El modelo secuencial mejora por los dos lados a la vez: deja escapar 20 fraudes menos y bloquea 58 compras buenas menos que el enfoque actual. Eso no siempre ocurre; normalmente hay que sacrificar uno para mejorar el otro.

7.1 Advertencia sobre las cifras absolutas

Los montos en quetzales están inflados y no deben tomarse como pronóstico. Salen de una tasa de fraude simulada de 0.66% de las transacciones, bastante por encima de la de una cartera real.

Lo que sí se sostiene es el 9.5% de ahorro relativo, porque ese porcentaje no depende de la escala que elegimos. Para convertirlo a quetzales, apliquen ese porcentaje sobre su pérdida por fraude observada.

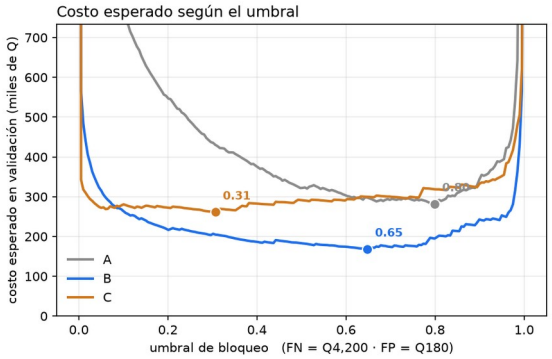


Figura 5. Costo esperado según el umbral, sobre validación. El punto marca el mínimo de cada curva.

8. Recomendación y límites *evidencia 6*

8.1 Complementar, no reemplazar

La evidencia da para esa palabra y no para otra.

El modelo secuencial no le gana al enfoque actual ni en F2 ni en F3. Cambiar el motor por este significaría perder una defensa que funciona, a cambio de una mejora que solo aparece en un mecanismo. Pero en ese mecanismo le gana con claridad, y es el caro: el cobro de un ataque de prueba y cobro anda entre Q2,000 y Q8,000.

Hay dos formas razonables de integrarlo:

- Correr ambos modelos y bloquear si cualquiera de los dos supera su umbral.
- Incorporar el puntaje del modelo secuencial como una variable más del motor de reglas que ya existe. Es menos invasiva y probablemente más rápida de implementar.

8.2 El error que sabemos que tiene

El goteo lento: cargos de Q80 a Q200 del mismo comercio, cada tres o cuatro días, durante semanas. Quedan por debajo de cualquier umbral de velocidad y los tres modelos los dejan pasar sin excepción. Esto no se arregla con un modelo de secuencias sobre ventanas de horas; necesita un detector distinto, que busque recurrencia sobre ventanas de semanas. Lo señalamos porque es un hueco real y conviene que el comité sepa que existe.

8.3 Bajo qué condiciones cambiaría la recomendación

- **Si los clientes que confunden al enfoque actual no existen en la cartera real.** Todo este resultado depende de que haya clientes legítimos que hacen varias compras chicas y después una grande, porque son los que hacen que las variables agregadas se equivoquen. Si en los datos del banco ese comportamiento es raro, los agregados bastarían. Es la primera hipótesis que habría que verificar, y se puede hacer con datos históricos sin entrenar nada.
- **Si bloquear cuesta bastante más que Q180.** El umbral sale bajo porque bloquear es barato. Si el costo reputacional de un bloqueo se pareciera al del fraude, el umbral subiría y la ventaja del modelo secuencial se achicaría.
- **Si los defraudadores cambian de patrón.** El caso F4 lo demuestra dentro del propio experimento. Un modelo supervisado defiende contra lo que ya ocurrió, así que hay que reentrenarlo con regularidad.

8.4 Qué haría falta para llevarlo a producción

- Transacciones reales con identificador de tarjeta, marca de tiempo y etiqueta de fraude, para confirmar que la ventaja del orden sobrevive fuera del simulador.
- La fecha en que se confirmó cada fraude, no solo la de la transacción. Las etiquetas reales llegan con semanas de retraso y eso cambia cómo se puede entrenar sin contaminar los datos.
- El costo real de un bloqueo, que aquí tomamos del supuesto de Q180.

9. Matriz de evidencias

Evidencia	Dónde está	Qué concluimos	Qué la limita
1. Integridad de datos	Sección 3, figura 1	484,753 transacciones, 0.66% de fraude, partición temporal con dos días de embargo y cinco controles contra fuga verificados automáticamente.	Los datos son sintéticos. La validez externa depende de que el generador se parezca a la cartera real, y eso está sin verificar.
2. Comparación A contra B	Sección 4, figura 2	El modelo secuencial alcanza 0.882 de AUC-PR contra 0.810 del enfoque actual, con la misma información de entrada.	Las columnas de validación y prueba no son comparables entre sí, porque en prueba se incluye un mecanismo no entrenado que cambia la frecuencia del fraude.
3. Valor del orden	Sección 5, figuras 3 y 4	Al barajar el orden el modelo secuencial cae de 0.882 a 0.018, y el de agregados no se mueve. La ventaja se concentra por completo en F1.	Mide el valor del orden en el fraude que nosotros construimos. No sabemos si el orden del fraude real tiene la misma estructura.
4. La hipótesis del equipo	Sección 6	El modelo híbrido no llegó al margen fijado de antemano. Quedó 0.026 por debajo del secuencial. Hipótesis rechazada.	El margen de 0.02 lo elegimos nosotros y no proviene de ningún estándar. Con un criterio más laxo el veredicto habría sido otro.
5. Umbral y costo	Sección 7, figura 5	Umbral en 0.648 minimizando costo esperado sobre validación. El modelo secuencial ahorra 9.5% frente al enfoque actual.	Las cifras absolutas en quetzales están infladas por la tasa de fraude simulada. Solo el porcentaje relativo es trasladable.
6. Recomendación y límites	Sección 8	Complementar el motor actual, no reemplazarlo. El punto ciego documentado es el goteo lento, que ningún modelo detecta.	La recomendación se cae si en la cartera real no existen los clientes legítimos que confunden a las variables agregadas.